

Prognoser for statlig bostøtte i Oslo

Arbeidsverk 2: maskinlæring, usikkerhet og kvalitetskontroll – sammenfatning av sju notebooks, med anbefalinger

Torkild M

9. august 2026

Innhold

Sammendrag	3
1 Hva arbeidet er	4
1.1 Datagrunnlaget	4
1.2 Hva som er kontrollert, og hva som ikke er det	4
2 Datagrunnlaget, og en feil i det	5
2.1 Kalenderen	5
2.2 Hvorfor gruppene reagerte ulikt	5
2.3 Hvor mye informasjon er det i femten bydeler?	6
3 Protokollen: hva en modell skal måles mot	6
4 Modellene: hva som virker	7
4.1 Stigen	7
4.2 Hvor langt fram kan vi se?	7
4.3 Hvor kommer signalet fra?	8
4.4 Hva prognosen er betinget av	8
4.5 Kapasitet	9
5 Usikkerhet: intervaller som holder det de lover	9
5.1 Lekkasjen i arbeidsverk 1	9
5.2 Et tall som var større enn det så ut som	10
6 Hierarkiet: Oslo og de femten delene	11
7 Kvalitetskontrollen: hva som ikke overlevde	11
7.1 To påstander som er trukket	11
7.2 En rapporteringsvane som skjulte et mønster	12
7.3 En kontroll som ikke kunne feile	12
7.4 Seks dokumenterte metodefeil	12
8 Anbefalinger	13
8.1 Til forskningsspørsmålet	13
8.2 Til prosjektet	13
8.3 Til Velferdsetaten	13
9 Hva som står åpent	14

i Note

Kolofon (versjon 2). Datavintage: Husbanken-uttrekk **4. august 2026**. Bygget mot commit d503897507ca med quarto render rapport/arbeidsverk2_sammenfatning.qmd (Quarto $\geq$ 1.7, R med tidyverse; miljøet er låst i repoets renv.lock). Grunnlaget er notebooks 01–07 i notebooks/ med lagret utdata, kvalitetskontrollens nyberegninger i notebook 07, og den uavhengige reproduksjonen i revisjon/repro_k7.py (15 av 15 K7-tall eksakt). **Versjonshistorikk:** førsteutgaven (16 sider, LaTeX; kildefilen er tapt) er arkivert uendret som arkiv/arbeidsverk2_sammenfatning_v1.pdf. Denne versjonen er en ny, sporbar kilde — ikke en rekonstruksjon av den tapte — med tre substansendringer, alle dokumentert i teksten der de står: modellnavnet *M7 orakel (øvre grense)* etter hovedrapportens kanoniske omdøping, en presisert formulering av panelfunnet i Seksjon 4.5, og statusnoter der arbeidsverk 1 senere har rettet feil denne rapporten påviste. Figurtallene er gjengitt fra de lagrede notebook-utdataene slik de står i v1; de er ikke regnet på nytt her, og K7-tallene er i tillegg uavhengig reproduert.

Arbeidsverk 1 bygde en prognosemodell for antall husstander med statlig bostøtte i Oslo, med rullerende opprinnelse og en modellstige i R. Arbeidsverk 2 tar den protokollen inn i Python, legger til maskinlæring, kalibrerte intervaller og hele bydelshierarkiet — og kontrollerer til slutt sine egne konklusjoner.

Kontrollen i notebook 07 er ikke en formalitet. Den trakk to av hovedpåstandene tilbake og snevret inn tre. Rapporten gjengir arbeidet slik det ser ut etter den kontrollen, og skiller gjennomgående mellom det som er kontrollert i kode, det som er beskrevet, og det som er antatt.

Arbeidet i tall

Notebooks	7
Forhåndsregistrerte påstander	19
Prognosepunkter per modell	372
Modeller skåret på samme protokoll	14
Tall reproduert fra arbeidsverk 1	16
Avvik i den reproduksjonen	0
Dokumenterte metodefeil	6
Rettelser etter kvalitetskontroll	13

Ramme

Datagrunnlag	Husbanken, statlig bostøtte, månedlig. Uttrekk 4. august 2026. Oslo 2010m1–2026m7 (199 måneder), 15 bydeler, 5 brukergupper
Evaluerings	Rullerende opprinnelse, 31 opprinnelser 2022m12–2025m6, $h = 1, \dots, 12$, 372 prognosepunkter per modell
Kode	github.com/Torcode/bostotte-oslo — notebooks/ 01–07

Sammendrag

Antall husstander med statlig bostøtte i Oslo lot seg prognostisere bedre enn en naiv framskrivning på alle tolv horisonter — men bare fordi modellen fikk vite når regelverket ble endret. Fryser man den kunnskapen til det som faktisk var kjent ved prognosetidspunktet, overlever fortrinnet på tre måneders sikt og forsvinner helt på tolv. Det er hovedfunnet, og det er samtidig svaret på hva slags problem dette egentlig er: serien er ikke i vesentlig grad autoregressiv, den er politikkstyrt.

Det som er kontrollert i kode.

- *En kalenderfeil i datagrunnlaget.* Seks av kolonnene i Husbankens uttrekk er ført i utbetalingsmåneden, ikke i terminmåneden. Feilen ga april 2024 et fall på $-0,2\%$ der det riktige tallet er $-25,2\%$. To eksakte identiteter og en bruddtest avgjør saken, alle som assert.
- *Protokollen lar seg flytte mellom språk.* Seksten publiserte tall fra arbeidsverk 1 er reproduisert i Python med null avvik. En tilpasningsalgoritme lar seg ikke flytte på samme måte, og det står oppgitt hvilke tall som er avskrift.
- *En lekkasje i arbeidsverk 1s intervallkalibrering.* Kalibreringen brukte prognosefeil som ennå ikke var observert. Lekkasjen er 11 prosentpoeng dekning, med $h = 1$ som innebygd kontroll: der skal de to skjemaene være identiske, og de er det. (*Statusnote v2: arbeidsverk 1 har siden lagt om til det tidsgyldige skjemaet med endelig-utvalgsnivå; dekningen der rapporteres nå som $48 \rightarrow 79\%$ på kalibreringsutvalget.*)
- *Hele fortrinnet ligger i domenekunnskapen.* Uten regelverksregressorene faller både treet, nettet og den lineære modellen under den naive prognosen. Og fryser man regressorene på det som var kjent ved opprinnelsen, går tolv månedersprognosen fra 25% bedre enn naiv til 20% dårligere. Kortsiktsprognosen tåler det; langsiktsprognosen gjør det ikke.
- *Overtilpasning er målt, ikke antatt.* Treningstilpasningen stiger fra $R^2 = 0,65$ til $0,99$ mens prognosefeilen stiger fra MASE $0,767$ til $0,964$.
- *Avstemming flytter treffsikkerhet fra helheten til delene.* Bydelsprognosene blir bedre, Oslo-totalen litt dårligere.

Det som ble trukket tilbake i kvalitetskontrollen.

- At ingen trebasert modell skiller seg fra den naive. Sammenlikningen er nøstet, og med riktig test passerer 13 av 36 celler den kritiske verdien i stedet for 0 av 36.
- At bydelsgevinsten er den sterkeste effekten i arbeidet. Femten bydeler som beveger seg i takt ble talt som femten uavhengige observasjoner. Retningen står; styrken faller.

Anbefalingene i korthet. (1) Til forskningsspørsmålet: skill mellom en prognose og et regnskap under gitte regler — ikke mekanisk mellom kort og lang horisont. (2) Til prosjektet: den mest verdifulle neste komponenten er ikke en ny modellklasse, men en versjonert regelverkstabell med kjent-fra-dato, og en driftsovervåkning som varsler på intervallskår framfor på treffsikkerhet. (3) Til Velferdsetaten: bruk bydelsnivået — det er der modellering betaler seg. Publisér intervaller, ikke punkter. Og vær varsom med enhver Oslo-analyse som slår sammen bydeler og rapporterer signifikans: den feilen ble gjort her, og den er lett å gjøre.

1 Hva arbeidet er

Arbeidet består av to deler. Arbeidsverk 1 er en rapport i R og Quarto som bygger en prognosemodell for antall husstander med statlig bostøtte i Oslo, med en evalueringsprotokoll og en modellstige fra naiv framskrivning til regresjon med ARIMA-feilledd. Arbeidsverk 2, som denne rapporten sammenfatter, er sju notebooks i Python. De sju er ikke sju forsøk på det samme; hver svarer på ett spørsmål som må være avklart før det neste kan stilles:

	Spørsmål	Svar
01	Hvor mye informasjon er det i datagrunnlaget?	Lite, og mindre enn radtallet tilsier. Femten bydeler bærer i hovedsak én bevegelse. Én kalenderfeil funnet og rettet
02	Hva skal en modell måles mot?	Protokollen flyttet fra R til Python og kontrollert mot seksten publiserte tall. Én lekkasje i arbeidsverk 1 målt
03	Hjelper trebasert maskinlæring?	Ja, på kort sikt, og bare med regelverksregressorene. Uten dem er den dårligere enn naiv
04	Hjelper mer kapasitet?	Nei. Nitten parametre slår nitten tusen. Panelet gjør den enkle modellen estimerbar med langt lavere varians
05	Kan intervallene kalibreres?	Delvis. Ingen variant nådde lovet nivå
06	Henger delene og helheten sammen?	Etter avstemming, ja — og bydelene tjener på det, ikke totalen
07	Holder konklusjonene?	Fem av seks ble avgjort med feil instrument. To påstander trekkes, tre snevres inn

1.1 Datagrunnlaget

Husbanken publiserer statlig bostøtte månedlig på tre nivåer: kommune, bydel og brukergruppe. Uttrekket her er datert 4. august 2026 og dekker 2010m1–2026m7 for Oslo, 199 måneder. Estimasjonsvinduet begynner 2017m1, fordi regelverket før det ikke er sammenliknbart, og ender 2026m6; siste måned i fila er tom fordi terminen ennå ikke er rapportert. Nivået i juni 2026 er 16 428 husstander.

Evalueringen bruker rullerende opprinnelse med utvidende vindu: minst 72 måneders trening, 31 opprinnelser fra 2022m12 til 2025m6, tolv horisonter fra hver. Det gir 372 prognosepunkter per modell, og de er de samme 372 for hver modell i hele arbeidet.

1.2 Hva som er kontrollert, og hva som ikke er det

Rapporten skiller tre nivåer, og skillet holdes gjennom hele teksten:

Kontrollert	Det finnes en assert eller en reproduisert verdi i koden. Kjøringen stopper hvis påstanden ikke holder
Målt	Tallet er regnet ut på de faktiske dataene, men uten en test som avgjør om det kunne oppstått ved tilfeldighet
Antatt	Forutsetning som er nødvendig for at resten skal gjelde, og som ikke er prøvd her

Den viktigste antakelsen i hele arbeidet står i notebook 03: modellen får vite at det midlertidige regelverket avvikles i april 2024 før det skjer, fordi vedtaket forelå. Det er samme forutsetning som arbeidsverk 1 gjør, og den er rimelig — men den er en antakelse, og en pipeline i drift må kunne dokumentere at datoen faktisk var kjent på prognosetidspunktet. (*Statusnote v2: hovedrapporten håndhever nå nettopp dette, med et primærkildebelagt kunnskapsregister og en point-in-time-port per opprinnelse — anbefaling 1 til prosjektet i Seksjon 8 er altså gjennomført.*)

2 Datagrunnlaget, og en feil i det

2.1 Kalenderen

Bostøtte har to datoer. Terminmåneden er måneden retten gjelder for. Utbetalingsmåneden er den 20. i måneden etter. Husbankens uttrekk fører noen kolonner i den ene kalenderen og noen i den andre, uten at kodeboken sier hvilke. Feilen dette gir, er ikke subtil:

Endring mars→april 2024	Uten korreksjon	Med korreksjon
Antall husstander	−0,2 %	−25,2 %
Gjennomsnittlig inntekt	+0,7 %	−16,1 %
Gjennomsnittlig boutgift	+0,2 %	+0,9 %
Gjennomsnittlig bostøtte	+1,3 %	+5,8 %
Antall over inntektstaket	—	−25,4 %

April 2024 er måneden det midlertidige regelverket ble avvirket. Uten korreksjonen ser avviklingen ut til å ha vært uten virkning. Med den er det den største enkeltbevegelsen i hele serien.

Belegg: To eksakte identiteter, begge assert: (i) $\text{ant_husstander_termin}(m) = \text{ant_husstander_utbetaling}(m + 1)$ i alle 197 par, null avvik; (ii) $\text{utbetalt_belop} = \text{antall} \times \text{snittbostøtte}$ stemmer til under to milliondeler når antallet hentes fra utbetalingsmåneden, og bommer med opptil 25 % fra terminmåneden. En tredje test bruker selve regelverksbruddet i april 2024 til å plassere de kolonnene ingen identitet dekker.

En kolonne — gjennomsnittlig boutgift — er ført opp som uavgjort framfor som bekreftet, fordi bruddtesten ikke skiller 0,7 fra 0,9 prosent. Den er klassifisert etter kodeboken alene og brukes ikke til noe som avhenger av hvilken måned den dateres i.

2.2 Hvorfor gruppene reagerte ulikt

Fallet i april 2024 var ikke jevnt fordelt. De fem brukergruppene ble rammet i en rekkefølge som er perfekt monoton i gruppens gjennomsnittsinntekt: gruppen med høyest inntekt mistet mest.

Belegg: Rangeringen er perfekt monoton. En eksakt permutasjonstest over alle $5! = 120$ tilordninger gir $p = 2/120$. Mekanismen er egenandelen, som er progressiv i inntekt. Med fem grupper er dette den sterkeste testen som er mulig, og den er svak; funnet er derfor ført som *målt*, ikke som *kontrollert*.

2.3 Hvor mye informasjon er det i femten bydeler?

Oslo har femten bydeler. Det ser ut som femten serier å lære av. Det er det ikke.

Belegg: Effektiv dimensjon, målt som deltakelsesforholdet til egenverdiene i korrelasjonsmatrisen, er 1,19 av 15 på de rå seriene. Fjernes den felles bevegelsen, stiger den til 11,33. Nesten all samvariasjon er én felles bevegelse; resten er nær uavhengig lokal støy.

Dette er det viktigste enkelttallet i notebook 01, og det får konsekvenser to steder senere: det forklarer hvorfor avstemming ikke kan hjelpe Oslo-totalen særlig (Seksjon 6), og det er selve grunnen til at bydelstesten i notebook 06 var feil (Seksjon 7).

3 Protokollen: hva en modell skal måles mot


Arbeidsverk 1 har en ferdig evalueringsprotokoll i R. Skal en Python-modell sammenliknes med den stigen, må protokollen flyttes over, og flyttingen må kontrolleres. Ellers måler man to ting med to linjaler og kaller forskjellen et resultat.

Belegg: Seksten publiserte tall fra arbeidsverk 1 — MASE, RMSE, dekning på 80 og 95 % og intervallskår for de to modellene som har lukket form, pluss fasevalget i kalenderregressoren — er reprodusert med uavhengig kode i Python med null avvik, til den presisjonen arbeidsverk 1 oppgir. Sammenlikningen er en assert.

Det som dermed er kontrollert, er hele skåringsapparatet. Det som ikke lar seg flytte, er like viktig: en tilpasningsalgoritme. `auto.arima` i R og en ARIMA-implementasjon i Python velger ulike modeller på samme data, ikke fordi den ene tar feil, men fordi søkestrategiene er ulike. De seks øverste trinnene i modellstigen er derfor avskrift fra arbeidsverk 1 og merket slik i hver tabell de opptrer i.

4 Modellene: hva som virker

4.1 Stigen



Figur 1: Modellstigen på tvers av begge arbeidsverk. MASE er gjennomsnittlig absolutt feil delt på en sesongnaiv referanse regnet i treningsvinduet; verdier under 1 er bedre enn naiv framskrivning. Grå søyler er arbeidsverk 1 (R, avskrift), petrol er arbeidsverk 2 (Python). Alle er skåret på de samme 372 prognosepunktene. M7 orakel får pålagt en koeffisient estimert på hele utvalget og er en øvre grense, ikke en operativ modell. Tallene er de lagrede notebook-utdataene (v1, fig. 1).

Hva vi ser på. Fjorten modeller, sortert. Den stiplede linjen er den naive prognosen — «neste måned blir som denne». Fem av modellene klarer ikke å slå den. Skillet mellom de gode og de dårlige går ikke på modellklasse — ETS, SARIMA, gradientboosting og nevrale nett ligger om hverandre — men på om modellen får vite når regelverket ble endret.

Den beste modellen er den enkleste. L0, en lineær regresjon med atten forklaringsvariabler tilpasset på panelet av alle seksten serier, gir MASE 0,767. Det er lavere enn gradientboosting (0,815), lavere enn ETS (0,931) — og lavere enn *M7 orakel* (0,838), som i tillegg får pålagt en koeffisient estimert på hele utvalget og dermed konkurrerer med perfekt informasjon.

4.2 Hvor langt fram kan vi se?


Trefferikkerheten faller med horisonten for alle modellene, og spørsmålet er om forskjellen mot naiv er større enn støyen per horisont.

Belegg: Clark–West passerer 1,64 i 13 av 36 celler. For G2 er det $h = 1-5$ pluss 7; for G1 er det $h = 1-4$ pluss 8, 9 og 10. Det relative fortrinnet på MASE er dessuten omtrent konstant over horisonten: G2 ligger 20 % under den naive prognosen i snitt over $h = 1-3$ og 16 % under over $h = 6-12$. Den lineære modellen forbedrer seg til og med mer på lang sikt enn på kort (20 % mot 25 %).

Hvorfor testen svekkes selv om modellen ikke gjør det. Langvariansen i Diebold–Mariano og Clark–West estimeres med et rektangulært vindu på $L = h - 1$ lag. Antall opprinnelser er 31 uansett horisont. Når h vokser, brukes altså flere og flere lag på et fast utvalg, og variansestimateret blir mer ustabil. Testen mister styrke raskere enn modellen mister trefferikkerhet. Det er en egenskap ved testoppsettet, ikke ved serien.

Hva som ikke følger. Clark–West avviser at de ekstra leddene er null i populasjonen. Det er ikke det samme som at modellen prognostiserer bedre i praksis; testen legger tilbake estimasjonskostnaden man faktisk betaler. MASE-rangeringen er målet som svarer på om modellen er verdt å bruke, og de to tallene skal ikke slås sammen.

4.3 Hvor kommer signalet fra?



Figur 2: Ablasjon: samme modell, samme protokoll, med og uten de fem regelverksregressorene (koronavindu, strømstøttevindu, tiltakspakken høsten 2024 og to kalenderregressorer). Stiplet linje er den naive prognosen. Tallene er de lagrede notebook-utdataene (v1, fig. 3).

Resultatet er entydig. Hver eneste modell faller fra under 1,0 til godt over. Uten regelverket er den mest avanserte modellen i arbeidet dårligere enn å gjette at neste måned blir som denne. Det gjelder like fullt for treet ($0,82 \rightarrow 1,25$), for nettet ($0,96 \rightarrow 1,55$) og for den lineære modellen ($0,77 \rightarrow 1,50$).

Hva det betyr. Hele fortrinnet over naiv framskrivning er domenekunnskap, ikke modellklasse. Serien er ikke i vesentlig grad autoregressiv – den er politikkstyrt. Det er den enkeltobservasjonen i arbeidet som har flest konsekvenser for hva som bør bygges videre, og den ligger til grunn for anbefaling 1 og 2 i Seksjon 8.

4.4 Hva prognosen er betinget av

Ablasjonen fjerner regelverksregressorene helt. Et mer presist spørsmål er hva som skjer når modellen har dem, men bare kjenner dem så langt fram som noen faktisk kunne vite ved prognosetidspunktet. Notebook 03 førte dette opp som åpent punkt og målte det aldri. Notebook 07 måler det: de tre vedtaksavhengige regressorene fryses på verdien de hadde ved opprinnelsen, og alt kjøres om igjen. Kalenderregressorene for utbetalingsfrekvens er deterministiske og røres ikke.

MASE	alle h	$h = 1-3$	$h = 6-12$
Naiv prognose (M0)	1,003	0,739	1,124
L0, regelverk kjent	0,767	0,584	0,848
L0, regelverk fryst	1,112	0,652	1,344
G2, regelverk kjent	0,815	0,584	0,939
G2, regelverk fryst	1,127	0,626	1,411

Kurvene skiller lag et bestemt sted. På én til tre måneder ligger kjent og fryst nær hverandre, og begge godt under den naive. Fra rundt seks måneder krysser den fryste banen over den naive.

Hvorfor fordelingen gir bildet. De vedtaksavhengige regressorene er trappefunksjoner med få trinn. Innenfor tre måneder fra en gitt opprinnelse er sannsynligheten liten for at et trinn faller i intervallet, så den fryste og den kjente regressoren er stort sett samme verdi. På tolv måneders sikt inneholder vinduet nesten alltid minst ett trinn — og det faller i akkurat de månedene som betyr mest.

Hva dette avgjør. Fortrinnet på kort sikt er ekte og overlever at framtidige vedtak er ukjente: 0,652 mot naivs 0,739. Fortrinnet på lang sikt gjør det ikke. Der går modellen fra 25 % bedre enn naiv til 20 % dårligere. **Tolv månedersprognosen er ikke en prognose. Den er en beregning betinget av at regelverkskalenderen er kjent et år fram.** Det gjør den ikke ubrukelig — det er nettopp slik en etat vil bruke den, med vedtatt regelverk lagt inn. Men den skal presenteres som et regnskap under gitte regler, ikke som en framskrivning. Forskjellen er ikke retorisk: den avgjør hvem som eier usikkerheten når reglene endrer seg.

4.5 Kapasitet

En naturlig neste tanke er at mer fleksible modeller ville gjort det bedre. Notebook 04 prøver den tanken direkte, med en stige av nevrale nett fra 8 til 128 skjulte enheter.

Belegg: Treningstilpasningen stiger fra $R^2 = 0,650$ til 0,989 mens prognosefeilen stiger fra MASE 0,767 til 0,964. De to kolonnene løper motsatt vei gjennom hele stigen. Modellen med 128 enheter har flere parametre enn treningssettet har rader.

Dette er overtilpasning målt framfor antatt: kapasitet er ikke en knapp faktor her. Datagrunnlaget er 114 måneder, og å legge til modellkompleksitet er å bruke frihetsgrader på noe som ikke finnes.

En beslektet observasjon fra samme notebook: panelet av seksten serier hjelper den lineære modellen mye (MASE 1,454 med bare Oslo, 0,767 med alle seksten) og nettet lite ($1,166 \rightarrow 0,964$).


Presisert (v2): mekanismen er variansreduksjon gjennom pooling — 672 observasjoner i stedet for 84 gir langt lavere estimeringsvarians for nitten koeffisienter, og det er *det* som forbedrer ut-av-utvalgsprognosene. Pooling etablerer ikke at koeffisientene er de sanne: panelet pålegger felles koeffisienter over seksten serier som ikke trenger å dele dem, så gevinsten er en bedre prognosemodell, ikke identifikasjon av strukturelle parametre. Førsteutgavens formulering — at koeffisientene «lar seg feste» med 672 observasjoner — sa mer enn målingen viser. Observasjonen er avlest av en kurve tegnet etter at prognosene forelå, og er ført som beskrivelse, ikke som test.

5 Usikkerhet: intervaller som holder det de lover

Et punkttestimat uten usikkerhet er ubrukelig for planlegging. Spørsmålet er om usikkerheten kan angis riktig.

5.1 Lekkasjen i arbeidsverk 1

Arbeidsverk 1 etterkalibrerte intervallene konformalt: for horisont h og opprinnelse τ bygges intervallet av den empiriske kvantilen til $|e_h|$ fra tidligere opprinnelser. «Tidligere opprinnelse» ble implementert som tidligere i rekkefølgen. Men en prognosefeil er ikke kjent ved opprinnelsen: feilen fra opprinnelse t_j på horisont h realiseres i $t_j + h$, og er tilgjengelig ved t_i bare hvis $t_j + h \leq t_i$. Arbeidsverk 1 krevde bare $t_j < t_i$. For $h = 1$ er kravene like; for $h = 12$ bruker kalibreringen feil som først blir kjent opptil elleve måneder etter at intervallet skulle vært stilt.



Figur 3: Hva de lovede 80 prosentene faktisk blir. Alle søylene er regnet på de samme 270 prognosepunktene, slik at forskjellene ikke er utvalgsforskjeller. Tallene er de lagrede notebook-utdataene (v1, fig. 5); dekomponeringen er uavhengig reproduert i revisjon/repro_protokoll.py.

Hva vi ser på. En dekomponering av avstanden mellom lovet og oppnådd dekning. Arbeidsverk 1s kalibrering treffer 78,5 % – nesten i mål, men med lånte feil. Fjernes lekkasjen, faller dekningen til 67,4 %. Legges den endelig-utvalgsgyldige kvantilen $\lceil (n+1)(1-\alpha) \rceil / n$ til – som split-konformal krever, og som ingen av notebookene før 06 brukte – stiger den til 74,4 %. Fem og et halvt prosentpoeng står igjen.

Hvorfor fordelingen gir bildet. Med n kalibreringspunkter er den empiriske 80-prosentkvan-tilen ikke forventningsrett for populasjonskvantilen; den ligger systematisk for lavt fordi $|e|$ er høyreskjev og en ordensstatistikk i et lite utvalg er skjev. Feilen går som $1/n$, og med n mellom ti og tjue – som er hva de lange horisontene faktisk har – er den synlig framfor neglisjerbar.

Hva som står igjen – og hvorfor det ikke lot seg avgjøre. Den nærliggende forklaringen på de siste 5,5 prosentpoengene er at bruddmånedene bryter utbyttbarheten, som er forutsetningen for konformal kalibrering. Hypotesen lot seg ikke prøve, og grunnen er selv et funn:

Belegg: 92 % av evalueringspunktene ligger innenfor tre måneder av en datert regelendring. Intervensjonstabellen har tjue oppføringer, og i 2021–2025 kommer de så tett at det knapt finnes rolige måneder å sammenlikne med. Stratifiseringen får 22 punkter mot 248, og forskjellen den viser – 77 mot 73 % – peker riktig vei, men hviler på for lite til å avgjøre noe.

For en etat er dette mer enn en statistisk detalj: i denne perioden var regelverket i praksis alltid i endring, og en modell som forutsetter en rolig grunntilstand har ingen grunntilstand å hvile på.

5.2 Et tall som var større enn det så ut som

Notebook 05 kalibrerte på prognosefeilene fra alle seksten seriene, og fikk fire til fem ganger så mange kalibreringspunkter. Løftet i dekning var mindre enn det burde tilsi.

Belegg: Kalibreringspunktene på tvers av serier er sterkt avhengige: gjennomsnittlig korrelasjon mellom to seriers absolutte logfeil er 0,90 på $h = 1$ og 0,62 på $h = 12$. Effektiv dimensjon er 1,2 til 2,0 av 16. De 304 punktene ved $h = 12$ er informasjonsmessig verdt om lag 38.

Det som ble målt i notebook 05, var at de seksten seriene har sammenliknbare marginale feilfordelinger. Det er riktig, og det er ikke det samme som utbyttbarhet. Et månedsavvik som treffer Oslo, treffer alle bydelene samtidig, fordi det er regelverket og ikke bydelen som flytter tallet.

6 Hierarkiet: Oslo og de femten delene

Prognosene for de seksten seriene summerte ikke opp: bydelene ble prognostisert hver for seg, og summen deres var ikke Oslo-prognosen. Notebook 06 avstemmer dem med fire metoder.

Metode	MASE Oslo	MASE bydel, snitt	Koherensavvik
Basis (ingen avstemming)	0,767	0,836	190 husst.
Bottom-up	0,825	0,836	0
Top-down	0,767	0,819	0
MinT, $W = I$	0,770	0,797	0
MinT, krymping	0,796	0,818	0

Hvordan tabellen skal leses. Kolonne to og tre løper motsatt vei. Metoden som er best for bydelene, MinT med $W = I$, er nest dårligst for Oslo. Bottom-up — å summere femten bydelsprognoser til en Oslo-prognose — er tydelig verst for totalen.

Hvorfor fordelingen gir bildet. Bydelene har mellom 363 og 2 212 mottakere i snitt; Oslo har 17 000. Å summere femten støyende prognoser gir mer varians enn å prognostisere totalen direkte. Motsatt vei har den velestimerte totalen mye å gi de støyende bydelene. Avstemming er derfor ikke en måte å forbedre totalen på; det er en måte å forbedre delene på, og prisen er en liten forverring på toppen.

En praktisk grense ved MinT. MinT med estimert kovarians er dårligere enn MinT med $W = I$, på begge nivåer. Krympingsintensiteten lander på 0,15 i median, altså brukes i hovedsak den rå kovariansmatrisen — og den er estimert på så få punkter at den bærer mer støy enn informasjon. Optimaliteten MinT lover, forutsetter en W man her ikke kan estimere.

7 Kvalitetskontrollen: hva som ikke overlevde

De seks første notebookene forhåndsregistrerte til sammen nitten påstander med avgjørelseskriterium skrevet ned før tallene fantes. Det gjør dem kontrollerbare på en måte de fleste analyser ikke er: man kan i ettetid spørre om avgjørelsen ble tatt med riktig instrument. Notebook 07 stiller det spørsmålet for de seks konklusjonene som bærer mest vekt. Fem av dem tålte ikke spørsmålet.

7.1 To påstander som er trukket

«**Ingen trebasert modell skiller seg fra den naive.**» Sammenlikningen er nøstet: alle modellene i stigen har formen $\hat{y}_{t+h} = \log y_t + f(x_t)$, og den naive prognosen er samme uttrykk med $f \equiv 0$. Under nullhypotesen estimerer den store modellen likevel f og betaler for det i varians; Diebold–Mariano regner den kostnaden som bevis for at den lille modellen er bedre. Clark–West fjerner den.

Belegg: Med Diebold–Mariano passerer 0 av 36 celler den kritiske verdien 1,64. Med Clark–West passerer 13 av 36, med opptil 2,80. Korreksjonsleddet $(e_1 - e_2)^2$ er positivt per konstruksjon, så forskjellen er systematisk og ikke støy. Notebook 02 skrev regelen ned og implementerte grenen som `noestet=True`; notebook 03 kalte funksjonen uten den.

«**Den sterkeste effekten i hele arbeidsverk 2.**» Bydelsgevinsten ble testet ved å stable femten bydelers tapsdifferanser i én vektor og behandle den som 465 uavhengige observasjoner.

Belegg: Gjennomsnittlig korrelasjon mellom to bydelers tapsdifferanse er 0,81, og effektiv dimensjon er 1,43 av 15 – samme egenskap ved bydelene som notebook 01 målte. Med klynging på opprinnelse (31 observasjoner) faller statistikken fra 5,38 til 1,56 på $h = 1$ og fra 2,99 til 0,91 på $h = 12$. MASE-forbedringen $0,836 \rightarrow 0,797$ er upåvirket.

Standardfeilen til et gjennomsnitt av K korrelerte størrelser går ikke som $1/\sqrt{K}$, men mot en grense satt av korrelasjonen: med $\rho \approx 0,8$ og $K = 15$ er den effektive prøvestørrelsen i underkant av to. Å stable femten bydeler er nesten ikke å legge til data.

7.2 En rapporteringsvane som skjulte et mønster

Notebook 03, 04 og 06 rapporterer alle $h \in \{1, 3, 6, 12\}$. Konvensjonen er arvet fra arbeidsverk 1 og er i seg selv rimelig – fire tall er lesbare, tolv er det ikke. Men den er et utvalg, og her valgte den feil: på de fire horisontene ser Clark–West-statistikken ut som en kurve som faller under kritisk verdi etter tre måneder; over alle tolv gjør den ikke det. Konklusjoner skal trekkes fra alle tolv, og en tabell som viser fire, bør si hva de tolv gjorde.

7.3 En kontroll som ikke kunne feile

Notebook 03 hadde to lekkasjekontroller. Den ene er ekte. Den andre var skrevet slik at konklusjonen fulgte av forutsetningen: variabelen som skulle testes ble beregnet og aldri brukt, og påstanden ble utledet på nytt fra en betingelse som allerede inneholdt den. Notebook 07 erstatter den med en mutasjonstest: funksjonen ødelegges med vilje, og kontrollen må stoppe. Den gamle kontrollen består selv når treningssettet slippes tolv måneder inn i framtiden. Den nye stopper. Konsekvensen for resultatene er null – funksjonen var riktig skrevet. Konsekvensen for hva som kan sies, er ikke null: en kontroll som ikke er vist å kunne stryke, hører ikke hjemme i et manifest.

7.4 Seks dokumenterte metodefeil

Feil	Hvordan den ble funnet	Virkning
Kalenderforveksling	to eksakte identiteter	april 2024: $-0,2 \rightarrow -25,2\%$
Konformal lekkasje	$t_j + h \leq t_i$ framfor $t_j < t_i$	11 pp dekning
Nettet ble aldri trent	tol slo inn etter 24 av 1 500 iterasjoner	modellstigen var tom
Radrekkefølge under sub-sample	0,8155 mot 0,8229 fra stablingsrekkefølge alene	reproduserbarhet
Manglende endelig-utvalgs-korreksjon	$\lceil (n+1)(1-\alpha) \rceil / n$	7 pp dekning
Tverrsnittsavhengighet som frihetsgrader	klynging på opprinnelse	$5,38 \rightarrow 1,56$

De fem første ble funnet mens arbeidet pågikk. Den sjette ble funnet ved å lese egne notebooks som om noen andre hadde skrevet dem. Fem av de seks er *stille* feil: koden kjørte, tallet kom ut, og ingenting varslet. Det er den typen feil et analysemiljø må bygge kontroller mot, fordi den ikke oppdages av at noe går galt.

8 Anbefalinger

8.1 Til forskningsspørsmålet

1. **Skill mellom en prognose og et regnskap — ikke mellom kort og lang horisont.** Modellen slår den naive framskrivningen på alle tolv horisontene, med en nesten konstant relativ margin. Det som ikke er konstant, er hva marginen er kjøpt med: på tre måneders sikt kommer den fra serien og regelverk som allerede er kjent; på tolv fra regelverk som ennå ikke er vedtatt på prognosetidspunktet. *Belegg: med regressorene fryst ved opprinnelsen går MASE på $h = 1-3$ fra 0,584 til 0,652 — fortsatt under naivs 0,739; på $h = 6-12$ fra 0,848 til 1,344, mot naivs 1,124. Fortrinnet inverteres.*
2. **Publiser tolvmånederstallet som betinget, med betingelsen skrevet ut.** Det er nyttig — det er slik en etat vil bruke det. Men det skal stå hvilke vedtak det forutsetter, og hva som skjer med tallet hvis de ikke kommer. Presenteres det som en framskrivning, blir en politisk beslutning lest som en spådom, og usikkerheten havner hos feil part.
3. **Flytt spørsmålet ned til bydel.** Avstemming forbedrer bydelsprognosene og forverrer totalen litt — og bydelene er der beslutningene tas. *Belegg: MASE over bydelene 0,836 $\rightarrow$ 0,797 med MinT; Oslo-totalen 0,767 $\rightarrow$ 0,770.*

Et fjerde punkt hører hjemme her, som en advarsel: serien er nesten flat mellom regelendringer og hopper kraftig ved dem. Gjennomsnittlig treffsikkerhet er derfor et misvisende mål alene — en modell kan ha lav MASE og likevel bomme fullstendig på nettopp de månedene noen bryr seg om. Intervallskår og bruddnær dekning bør stå ved siden av MASE i enhver rapportering.

8.2 Til prosjektet

1. **Bygg en versjonert regelverkstabell med kjent-fra-dato.** Tre datoer per endring: vedtaksdato, kunngjøringsdato, virkningsdato. Med den kan enhver prognose kjøres to ganger — én gang med det som var kjent, én gang med fasit — og forskjellen er et målt usikkerhetsbidrag framfor en advarsel i en fotnote. (*Statusnote v2: gjennomført i hovedrapporten — data/clean/regelverk_kunnskap.csv med primærkildebelagte kunnskapsdatoer og en håndhevet point-in-time-port; frysingene her var den konservative tilnærmingen, og den sanne betingede treffsikkerheten ligger mellom fryst og kjent, slik denne rapporten antok.*)
2. **Legg til driftsovervåkning — og varsle på intervallskår, ikke på MASE.** MASE-nevneren regnes i treningsvinduet og vokser når serien blir mer volatil, så MASE faller når verden blir vanskeligere. Intervallskåren straffer bom direkte og har ikke den egenskapen.
3. **Lukk de to åpne punktene som er billige:** hyperparametersøk (nestet kryssvalidering innenfor treningsvinduet) og spredning over frø.
4. **Be om individdata.** Gruppemekanismen i april 2024 ble sannsynliggjort med en eksakt permutasjonstest over fem grupper, $p = 2/120$ — den sterkeste testen som er mulig med fem grupper, og den er svak. Med husstands nivå er mekanismen direkte målbar, og egenandelsstrukturen kan simuleres framfor estimeres.
5. **Skriv ferdig det som er lovet.** Notebook 01 har to avsnitt som fortsatt er punktlistes. (*Statusnote v2: README-løftet om BSTS er ryddet — utvidelsen står nå i hovedrapportens teorikapittel som mulig utvidelse, ikke som løfte i README.*)

8.3 Til Velferdsetaten

1. **Publiser intervaller, ikke punkter — og oppgi den målte dekningen.** Et 80 %-intervall som treffer 74 % er brukbart hvis det står at det treffer 74 %. Det er ubrukelig hvis det står 80.
2. **Bruk bydelsnivået, og avstem det.** Bydelene tar beslutningene, og det er der modellering betaler seg; avstemming koster nesten ingenting på totalen.

3. **Institusjonaliser regelverkskalenderen.** En datert, versjonert oversikt over regelendringer i bostøtten — med kunngjøringsdato, ikke bare virkningsdato — er en ren forvaltningsoppgave, og den er en forutsetning for at enhver modell skal virke. Uten den er den beste modellen i dette arbeidet dårligere enn å gjette.
4. **Vær varsom med bydelspooling.** Femten bydeler er ikke femten uavhengige observasjoner (effektiv dimensjon 1,2 av 15 på nivåene, 1,4 på prognosefeilene). Enhver analyse som slår sammen bydeler og rapporterer signifikans, risikerer å overdrive styrken på funnene sine med en faktor rundt tre. Denne feilen ble gjort i dette arbeidet og fanget i kvalitetskontrollen.
5. **Ikke regn med en rolig grunntilstand.** 92 % av evalueringspunktene ligger innenfor tre måneder av en datert regelendring; «normal drift» er ikke en tilstand denne serien har vært i på fem år. Bygg regelendringer inn som en forventet del av modellen, og ikke bruk historisk gjennomsnittlig treffsikkerhet som løfte om framtidig.
6. **Sett krav til analyseleveranser.** Fire krav ville fanget alle seks feilene dokumentert her: forhåndsregistrering av påstander med avgjørelseskriterium; en protokoll som er reproduert uavhengig; lekkasjekontroller som er vist å kunne stryke; og en endringslogg som bærer grunnen til hver endring. Dette gjelder like mye for innkjøpt analyse som for egenprodusert.
7. **Skill mellom prognose og regnskap i det som publiseres.** Antall bostøttmottakere om tolv måneder er i hovedsak et spørsmål om hvilke regler som gjelder da. Presenteres det som et regnskap under gitte regler, blir det et beslutningsgrunnlag.

9 Hva som står åpent

Ærlighet om det som ikke er gjort, hører til i samme rapport som det som er.

- **Ingen hyperparametersøk, ett frø.** Resultatene sier ingenting om hva modellene kunne oppnådd med justering, og spredningen mellom frø er ukjent.
- **Seks trinn i modellstigen er avskrift.** De er merket slik i hver tabell. Diebold–Mariano-implementasjonen er gjengitt fra arbeidsverk 1 ledd for ledd, men ikke kontrollert mot et publisert tall.
- **Ingen driftskomponent.** Ingen drift-deteksjon, retreningspolicy eller overvåkning; se anbefaling 2 til prosjektet.
- **«Det som var kjent» var tilnærmet her.** Frysingene i notebook 07 bærer siste verdi framover — konservativt, siden noen vedtak var kjent før virkningsdato. (*Statusnote v2: hovedrapportens kunnskapsregister med effect_known_from har siden avgjort dette; se dens kapittel om point-in-time-porten.*)
- **Kvalitetskontrollen er ikke uttømmende.** Notebook 07 prøver de seks konklusjonene som bærer mest vekt; fravær av flere funn er ikke belegg for at det ikke finnes flere.
- **Uttrekket selv er ikke kontrollert her.** Om Husbankens tall er riktige, ligger utenfor det som kan avgjøres herfra. (*Hovedrapporten validerer uttrekket eksternt mot publiserte nasjonale årstall.*)
- **Bruddmånedsforklaringen er ikke testet.** Stratifiseringen peker den veien; den er beskrivelse, ikke test.

Alt tallmateriale i denne rapporten er regnet på nytt fra kildedataene i notebook 07, uten å lese resultater fra notebook 01–06; K7-tabellens femten tall er i tillegg uavhengig reproduert i revisjon/repro_k7.py. Notebookene ligger i github.com/Torcode/bostotte-oslo under notebooks/, og hver av dem sammenlikner sitt eget kildeavtrykk med det som ligger på main før den rapporterer noe. Endringsloggen i logg/ bærer grunnen til hver endring.