

## Prognoser for statlig bostøtte i Oslo

# Arbeidsverk 2: maskinlæring, usikkerhet og kvalitetskontroll

Sammenfatning av sju notebooks, med anbefalinger

---

Arbeidsverk 1 bygde en prognosemodell for antall husstander med statlig bostøtte i Oslo, med rullerende opprinnelse og en modellstige i R. Arbeidsverk 2 tar den protokollen inn i Python, legger til maskinlæring, kalibrerte intervaller og hele bydelshierarkiet — og kontrollerer til slutt sine egne konklusjoner.

Kontrollen i notebook 07 er ikke en formalitet. Den trakk to av hovedpåstandene tilbake og snevret inn tre. Denne rapporten gjengir arbeidet slik det ser ut *etter* den kontrollen, og skiller gjennomgående mellom det som er kontrollert i kode, det som er beskrevet, og det som er antatt.

### Arbeidet i tall

|     |                                    |    |                                    |
|-----|------------------------------------|----|------------------------------------|
| 7   | notebooks                          | 19 | forhåndsregistrerte påstander      |
| 372 | prognosepunkter per modell         | 14 | modeller skåret på samme protokoll |
| 16  | tall reproducert fra arbeidsverk 1 | 0  | avvik i den reproduksjonen         |
| 6   | dokumenterte metodefeil            | 13 | rettelser etter kvalitetskontroll  |

|                     |                                                                                                                                  |
|---------------------|----------------------------------------------------------------------------------------------------------------------------------|
| <b>Datagrunnlag</b> | Husbanken, statlig bostøtte, månedlig. Uttrekk 4. august 2026.<br>Oslo 2010m1–2026m7 (199 måneder), 15 bydeler, 5 brukergrupper. |
| <b>Evaluerings</b>  | Rullerende opprinnelse, 31 opprinnelser 2022m12–2025m6,<br>$h = 1 \dots 12$ , 372 prognosepunkter per modell.                    |
| <b>Kode</b>         | <a href="https://github.com/Torcode/bostotte-oslo">github.com/Torcode/bostotte-oslo</a> — notebooks 01–07.                       |
| <b>Reproduksjon</b> | Hver notebook sjekker sitt eget kildeavtrykk mot main og stopper på assert hvis datagrunnlaget avviker.                          |

## Sammendrag

Antall husstander med statlig bostøtte i Oslo lot seg prognostisere bedre enn en naiv framskrivning på alle tolv horisonter — men bare fordi modellen fikk vite når regelverket ble endret. Fryser man den kunnskapen til det som faktisk var kjent ved prognosetidspunktet, overlever fortrinnet på tre måneders sikt og forsvinner helt på tolv. Det er hovedfunnet, og det er samtidig svaret på hva slags problem dette egentlig er: serien er ikke i vesentlig grad autoregressiv, den er politikkstyrt.

### Det som er kontrollert i kode.

- **En kalenderfeil i datagrunnlaget.** Seks av kolonnene i Husbankens uttrekk er ført i utbetalingsmåneden, ikke i terminmåneden. Feilen ga april 2024 et fall på  $-0,2\%$  der det riktige tallet er  $-25,2\%$ . To eksakte identiteter og en bruddtest avgjør saken, alle som assert.
- **Protokollen lar seg flytte mellom språk.** Seksten publiserte tall fra arbeidsverk 1 er reproduert i Python med null avvik. En tilpasningsalgoritme lar seg ikke flytte på samme måte, og det står oppgitt hvilke tall som er avskrift.
- **En lekkasje i arbeidsverk 1s intervallkalibrering.** Kalibreringen brukte prognosefeil som ennå ikke var observert. Lekkasjen er 11 prosentpoeng dekning, med  $h = 1$  som innebygd kontroll: der skal de to skjemaene være identiske, og de er det.
- **Hele fortrinnet ligger i domenekunnskapen.** Uten regelverksregressorene faller både treet, nettet og den lineære modellen under den naive prognosen. Og fryser man regressorene på det som var kjent ved opprinnelsen, går tolv månedersprognosen fra  $25\%$  bedre enn naiv til  $20\%$  dårligere. Kortsiktsprognosen tåler det; langsiktsprognosen gjør det ikke.
- **Overtilpasning er målt, ikke antatt.** Treningstilpasningen stiger fra  $R^2 = 0,65$  til  $0,99$  mens prognosefeilen stiger fra MASE  $0,767$  til  $0,964$ .
- **Avstemming flytter treffsikkerhet fra helheten til delene.** Bydelsprognosene blir bedre, Oslo-totalen litt dårligere.

### Det som ble trukket tilbake i kvalitetskontrollen.

- At ingen trebasert modell skiller seg fra den naive. Sammenlikningen er nøstet, og med riktig test passerer 13 av 36 celler den kritiske verdien i stedet for 0 av 36.
- At bydelsgevinsten er den sterkeste effekten i arbeidet. Femten bydeler som beveger seg i takt ble talt som femten uavhengige observasjoner. Retningen står; styrken faller.

### Anbefalingene i korthet.

1. **Til forskningsspørsmålet:** del det i to. Én kortsiktig driftsprognose ( $h \leq 3$ ) som står på egne bein, og ett *regelverksregnskap* for lengre sikt — et tall betinget av vedtatt regelverk, merket som sådan. De to har ulik status og bør ikke publiseres som samme produkt.
2. **Til prosjektet:** den mest verdifulle neste komponenten er ikke en ny modellklasse, men en versjonert regelverkstabell med *kjent-fra*-dato, og en driftsovervåkning som varsler på intervallskår framfor på treffsikkerhet.
3. **Til Velferdsetaten:** bruk bydelsnivået — det er der modellering betaler seg. Publisér intervaller, ikke punkter. Og vær varsom med enhver Oslo-analyse som slår sammen bydeler og rapporterer signifikans: den feilen ble gjort her, og den er lett å gjøre.

## Innhold

|                                                              |           |
|--------------------------------------------------------------|-----------|
| <b>Sammendrag</b>                                            | <b>2</b>  |
| <b>1 Hva arbeidet er</b>                                     | <b>4</b>  |
| 1.1 Datagrunnlaget . . . . .                                 | 4         |
| 1.2 Hva som er kontrollert, og hva som ikke er det . . . . . | 4         |
| <b>2 Datagrunnlaget, og en feil i det</b>                    | <b>5</b>  |
| 2.1 Kalenderen . . . . .                                     | 5         |
| 2.2 Hvorfor gruppene reagerte ulikt . . . . .                | 5         |
| 2.3 Hvor mye informasjon er det i femten bydeler? . . . . .  | 5         |
| <b>3 Protokollen: hva en modell skal måles mot</b>           | <b>6</b>  |
| <b>4 Modellene: hva som virker</b>                           | <b>6</b>  |
| 4.1 Stigen . . . . .                                         | 6         |
| 4.2 Hvor langt fram kan vi se? . . . . .                     | 7         |
| 4.3 Hvor kommer signalet fra? . . . . .                      | 8         |
| 4.4 Hva prognosen er betinget av . . . . .                   | 8         |
| 4.5 Kapasitet . . . . .                                      | 9         |
| <b>5 Usikkerhet: intervaller som holder det de lover</b>     | <b>10</b> |
| 5.1 Lekkasje i arbeidsverk 1 . . . . .                       | 10        |
| 5.2 Et tall som var større enn det så ut som . . . . .       | 11        |
| <b>6 Hierarkiet: Oslo og de femten delene</b>                | <b>11</b> |
| <b>7 Kvalitetskontrollen: hva som ikke overlevde</b>         | <b>12</b> |
| 7.1 To påstander som er trukket . . . . .                    | 12        |
| 7.2 En rapporteringsvane som skjulte et mønster . . . . .    | 12        |
| 7.3 En kontroll som ikke kunne feile . . . . .               | 12        |
| 7.4 Seks dokumenterte metodefeil . . . . .                   | 13        |
| <b>8 Anbefalinger</b>                                        | <b>13</b> |
| 8.1 Til forskningsspørsmålet . . . . .                       | 13        |
| 8.2 Til prosjektet . . . . .                                 | 14        |
| 8.3 Til Velferdsetaten . . . . .                             | 14        |
| <b>9 Hva som står åpent</b>                                  | <b>15</b> |

## 1 Hva arbeidet er

Arbeidet består av to deler. Arbeidsverk 1 er en rapport i R og Quarto som bygger en prognosemodell for antall husstander med statlig bostøtte i Oslo, med en evalueringsprotokoll og en modellstige fra naiv framskrivning til regresjon med ARIMA-feilledd. Arbeidsverk 2, som denne rapporten sammenfatter, er sju notebooks i Python.

De sju er ikke sju forsøk på det samme. Hver av dem svarer på ett spørsmål som må være avklart før det neste kan stilles:

|    | Spørsmål                                      | Svar                                                                                                                   |
|----|-----------------------------------------------|------------------------------------------------------------------------------------------------------------------------|
| 01 | Hvor mye informasjon er det i datagrunnlaget? | Lite, og mindre enn radtallet tilsier. Femten bydeler bærer i hovedsak én bevegelse. Én kalenderfeil funnet og rettet. |
| 02 | Hva skal en modell måles mot?                 | Protokollen flyttet fra R til Python og kontrollert mot seksten publiserte tall. Én lekkasje i arbeidsverk 1 målt.     |
| 03 | Hjelper trebasert maskinlæring?               | Ja, på kort sikt, og bare med regelverksregressorene. Uten dem er den dårligere enn naiv.                              |
| 04 | Hjelper mer kapasitet?                        | Nei. Nitten parametre slår nitten tusen. Panelet gjør den enkle modellen identifiserbar.                               |
| 05 | Kan intervallene kalibreres?                  | Delvis. Ingen variant nådde lovet nivå.                                                                                |
| 06 | Henger delene og helheten sammen?             | Etter avstemming, ja — og bydelene tjener på det, ikke totalen.                                                        |
| 07 | Holder konklusjonene?                         | Fem av seks ble avgjort med feil instrument. To påstander trekkes, tre snevres inn.                                    |

### 1.1 Datagrunnlaget

Husbanken publiserer statlig bostøtte månedlig på tre nivåer: kommune, bydel og brukergruppe. Uttrekket her er datert 4. august 2026 og dekker 2010m1–2026m7 for Oslo, 199 måneder. Estimasjonsvinduet begynner 2017m1, fordi regelverket før det ikke er sammenliknbart, og ender 2026m6; siste måned i fila er tom fordi terminen ennå ikke er rapportert. Nivået i juni 2026 er 16 428 husstander.

Evalueringen bruker rullerende opprinnelse med utvidende vindu: minst 72 måneders trening, 31 opprinnelser fra 2022m12 til 2025m6, tolv horisonter fra hver. Det gir 372 prognosepunkter per modell, og de er de samme 372 for hver modell i hele arbeidet.

### 1.2 Hva som er kontrollert, og hva som ikke er det

Rapporten skiller tre nivåer, og skillet holdes gjennom hele teksten.

|                    |                                                                                                                 |
|--------------------|-----------------------------------------------------------------------------------------------------------------|
| <b>Kontrollert</b> | Det finnes en assert eller en reprodusert verdi i koden. Kjøringen stopper hvis påstanden ikke holder.          |
| <b>Målt</b>        | Tallet er regnet ut på de faktiske dataene, men uten en test som avgjør om det kunne oppstått ved tilfeldighet. |
| <b>Antatt</b>      | Forutsetning som er nødvendig for at resten skal gjelde, og som ikke er prøvd her.                              |

Den viktigste antakelsen i hele arbeidet står i notebook 03: modellen får vite at det midlertidige regelverket avvikes i april 2024 *før* det skjer, fordi vedtaket forelå. Det er

samme forutsetning som arbeidsverk 1 gjør, og den er rimelig — men den er en antakelse, og en pipeline i drift må kunne dokumentere at datoen faktisk var kjent på prognosetidspunktet. Anbefaling 2 i avsnitt 9 handler om nettopp det.

## 2 Datagrunnlaget, og en feil i det

### 2.1 Kalenderen

Bostøtte har to datoer. *Terminmåneden* er måneden retten gjelder for. *Utbetalingsmåneden* er den 20. i måneden etter. Husbankens uttrekk fører noen kolonner i den ene kalenderen og noen i den andre, uten at kodeboken sier hvilke.

Feilen dette gir, er ikke subtil. Sammenlikner man april 2024 med mars 2024 uten å korrigere, får man tallene i venstre kolonne under. Med korreksjonen får man de i høyre.

| Endring mars→april 2024   | Uten korreksjon | Med korreksjon |
|---------------------------|-----------------|----------------|
| Antall husstander         | −0,2 %          | −25,2 %        |
| Gjennomsnittlig inntekt   | +0,7 %          | −16,1 %        |
| Gjennomsnittlig boutgift  | +0,2 %          | +0,9 %         |
| Gjennomsnittlig bostøtte  | +1,3 %          | +5,8 %         |
| Antall over inntektstaket | —               | −25,4 %        |

April 2024 er måneden det midlertidige koronaregelverket ble avvirket. Uten korreksjonen ser avviklingen ut til å ha vært uten virkning. Med den er det den største enkeltbevegelsen i hele serien.

**Belegg:** To eksakte identiteter, begge assert: (i)  $\text{ant\_husstander\_termin}(m) = \text{ant\_husstander\_utbetaling}(m+1)$  i alle 197 par, null avvik; (ii)  $\text{utbetaalt\_belop} = \text{antall} \times \text{snittbostøtte}$  stemmer til under to milliondeler når antallet hentes fra utbetalingsmåneden, og bommer med opptil 25 % fra terminmåneden. En tredje test bruker selve regelverksbruddet i april 2024 til å plassere de kolonnene ingen identitet dekker.

En kolonne — gjennomsnittlig boutgift — er ført opp som *uavgjort* framfor som bekreftet, fordi bruddtesten ikke skiller 0,7 fra 0,9 prosent. Den er klassifisert etter kodeboken alene og brukes ikke til noe som avhenger av hvilken måned den dateres i.

### 2.2 Hvorfor gruppene reagerte ulikt

Fallet i april 2024 var ikke jevnt fordelt. De fem brukergruppene ble rammet i en rekkefølge som er perfekt monoton i gruppens gjennomsnittsinntekt: gruppen med høyest inntekt mistet mest.

**Belegg:** Rangeringen er perfekt monoton. En eksakt permutasjonstest over alle  $5! = 120$  tilordninger gir  $p = 2/120$ . Mekanismen er egenandelen, som er progressiv i inntekt: en inntektsøkning på 1 000 kroner reduserer bostøtten med 0,28 % for den laveste gruppen og 0,12 % for den høyeste. Med fem grupper er dette den sterkeste testen som er mulig, og den er svak; funnet er derfor ført som *målt* og ikke som *kontrollert*.

### 2.3 Hvor mye informasjon er det i femten bydeler?

Oslo har femten bydeler. Det ser ut som femten serier å lære av. Det er det ikke.

**Belegg:** Effektiv dimensjon, målt som deltakelsesforholdet til egenverdiene i korrelasjonsmatrisen, er **1,19** av 15 på de rå seriene. Fjernes den felles bevegelsen, stiger den til 11,33. Med andre ord: nesten all samvariasjon er én felles bevegelse, og det som blir igjen etterpå er nær uavhengig lokal støy.

Dette tallet er det viktigste enkelttallet i notebook 01, og det får konsekvenser to steder senere. Det forklarer hvorfor avstemming ikke kan hjelpe Oslo-totalen særlig (avsnitt 7),

og det er selve grunnen til at bydelstesten i notebook 06 var feil (avsnitt 8). At det samme tallet både ble brukt til å forutsi ett resultat og oversett i beregningen av et annet, er verdt å merke seg: en målt egenskap ved dataene hjelper bare hvis den huskes der den er relevant.

### 3 Protokollen: hva en modell skal måles mot

Arbeidsverk 1 har en ferdig evalueringsprotokoll i R. Skal en Python-modell sammenliknes med den stigen, må protokollen flyttes over, og flyttingen må kontrolleres. Ellers måler man to ting med to linjaler og kaller forskjellen et resultat.


**Belegg:** Seksten publiserte tall fra arbeidsverk 1 — MASE, RMSE, dekning på 80 og 95 % og intervallskår for de to modellene som har lukket form, pluss fasevalget i kalenderregressoren — er reproduisert med uavhengig kode i Python med **null avvik**, til den presisjonen arbeidsverk 1 oppgir. Sammenlikningen er en assert.

Det som dermed er kontrollert, er hele skåringsapparatet: hvilke opprinnelser som inngår, hvilke horisonter, hvordan MASE-nevneren regnes (sesongnaiv på nivåskala, kun i treningsvinduet ved hver opprinnelse), hvordan log tilbaketransformeres, hvordan intervaller bygges og hvordan intervallskåren straffer.

Det som *ikke* lar seg flytte, er like viktig: en tilpasningsalgoritme. `auto.arima` i R og en ARIMA-implementasjon i Python vil velge ulike modeller på samme data, ikke fordi den ene tar feil, men fordi søkestrategiene er ulike. De seks øverste trinnene i modellstigen er derfor *avskrift* fra arbeidsverk 1 og merket slik i hver tabell de opptrer i. Et generelt poeng ligger her: *en protokoll kan flyttes mellom språk og kontrolleres numerisk; en tilpasningsalgoritme kan det som regel ikke.*

## 4 Modellene: hva som virker

### 4.1 Stigen




Figur 1: Modellstigen på tvers av begge arbeidsverk. MASE er gjennomsnittlig absolutt feil delt på en sesongnaiv referanse regnet i treningsvinduet; verdier under 1 er bedre enn naiv framskrivning. Grå søyler er arbeidsverk 1 (R), blå er arbeidsverk 2 (Python). Alle er skåret på de samme 372 prognosepunktene.

**Hva vi ser på.** Elleve modeller, sortert. Den røde streken er den naive prognosen — «neste måned blir som denne måneden». Fem av de fjorten modellene i arbeidet klarer ikke å slå den.

**Hvordan fordelingen gir bildet.** Serien har et sterkt nivå og svake bevegelser rundt det. En modell som prognostiserer nivået direkte, konkurrerer derfor mot et anker som allerede er nesten riktig; det er grunnen til at MASE ligger tett rundt 1 for hele den øverste halvparten av stigen. Skillet mellom de gode og de dårlige modellene går ikke på modellklasse — ETS, SARIMA, gradientboosting og nevrale nett ligger om hverandre — men på om modellen får vite når regelverket ble endret. De fire beste gjør det. De fire dårligste gjør det ikke, eller får det i en form de ikke kan bruke.

**Den beste modellen er den enkleste.** L0, en lineær regresjon med atten forklaringsvariabler tilpasset på panelet av alle seksten serier, gir MASE 0,767. Det er lavere enn gradientboosting (0,815), lavere enn ETS (0,931), og lavere enn arbeidsverk 1s beste modell (0,838), som i tillegg får pålagt en koeffisient estimert på hele utvalget.

## 4.2 Hvor langt fram kan vi se?



Figur 2: Venstre: treffsikkerhet per horisont for den naive prognosen og de to beste modellene. Høyre: Clark–West-statistikken for de to trebaserte modellene mot den naive. Clark–West er testen som hører til en nøstet sammenlikning; se avsnitt 8.

**Hva vi ser på.** Til venstre stiger alle tre kurvene med horisonten — det er ventet, prognoser blir dårligere jo lenger fram de går. Til høyre er avstanden mellom kurvene gjort om til en teststatistikk, for hver av de tolv horisontene.

**Et bilde som endrer seg med hvilke horisonter man viser.** Notebook 03, 04 og 06 rapporterer alle  $h \in \{1, 3, 6, 12\}$ . På de fire ser det ut som om signalet forsvinner etter tre måneder. Over alle tolv gjør det ikke det.


**Belegg:** Clark–West passerer 1,64 i 13 av 36 celler. For  $G_2$  er det  $h = 1$  til 5 pluss 7; for  $G_1$  er det  $h = 1$  til 4 pluss 8, 9 og 10. Det relative fortrinnet på MASE er dessuten omtrent *konstant* over horisonten:  $G_2$  ligger 20 % under den naive prognosen i snitt over  $h = 1$ –3 og 16 % under over  $h = 6$ –12. Den lineære modellen forbedrer seg til og med mer på lang sikt enn på kort (20 % mot 25 %).

**Hvorfor testen svekkes selv om modellen ikke gjør det.** Langvariansen i Diebold–Mariano og Clark–West estimeres med et rektangulært vindu på  $L = h - 1$  lag. Antall opprinnelser er 31 uansett horisont. Når  $h$  vokser, brukes altså flere og flere lag på et fast utvalg, og variansestimater blir mer ustabil. **Testen mister styrke raskere enn modellen mister treffsikkerhet.** Det er en egenskap ved testoppsettet, ikke ved serien, og den bør ikke

leses som at prognosen slutter å virke.

**Hva som ikke følger.** Clark–West avviser at de ekstra leddene er null i populasjonen. Det er ikke det samme som at modellen prognostiserer bedre i praksis; testen legger tilbake estimasjonskostnaden man faktisk betaler. MASE-rangeringen er målet som svarer på om modellen er verdt å bruke, og de to tallene skal ikke slås sammen.

### 4.3 Hvor kommer signalet fra?



Figur 3: Ablasjon: samme modell, samme protokoll, med og uten de fem regelverksregressorene (koronavindu, strømstøttevindu, tiltakspakken høsten 2024, og to kalenderregressorer for utbetalingsfrekvens). Stiplet linje er den naive prognosen.

**Hva vi ser på.** Fire modeller kjørt to ganger hver. De blå søylene er modellene slik de brukes. De røde er de samme modellene med regelverksregressorene fjernet og ingenting annet endret.


**Resultatet er entydig.** Hver eneste modell faller fra under 1,0 til godt over. Uten regelverket er den mest avanserte modellen i arbeidet dårligere enn å gjette at neste måned blir som denne. Det gjelder like fullt for treet ( $0,82 \rightarrow 1,25$ ), for nettet ( $0,96 \rightarrow 1,55$ ) og for den lineære modellen ( $0,77 \rightarrow 1,50$ ).

**Hva det betyr.** Hele fortrinnet over naiv framskrivning er domenekunnskap, ikke modellklasse. Serien er ikke i vesentlig grad autoregressiv — den er politikkstyrt. Det er den enkeltobservasjonen i arbeidet som har flest konsekvenser for hva som bør bygges videre, og den ligger til grunn for anbefaling 1 og 2.

### 4.4 Hva prognosen er betinget av

Ablasjonen fjerner regelverksregressorene helt. Et mer presist spørsmål er hva som skjer når modellen har dem, men bare kjenner dem så langt fram som noen faktisk kunne vite ved prognosetidspunktet. Notebook 03 førte dette opp som åpent punkt og målte det aldri. Notebook 07 måler det: de tre vedtaksavhengige regressorene fryses på verdien de hadde ved opprinnelsen, og alt kjøres om igjen. Kalenderregressorene for utbetalingsfrekvens er deterministiske og røres ikke.





Figur 4: Samme modell, samme protokoll, to informasjonssett. Blå og grønn: regressoren i målmåneden har sin faktiske verdi, slik notebook 03–06 bruker den. Rød: regressoren bærer siste kjente verdi fra opprinnelsen framover.

| MASE                | alle $h$     | $h = 1-3$    | $h = 6-12$   |
|---------------------|--------------|--------------|--------------|
| Naiv prognose (M0)  | 1,003        | 0,739        | 1,124        |
| L0, regelverk kjent | <b>0,767</b> | <b>0,584</b> | <b>0,848</b> |
| L0, regelverk fryst | 1,112        | 0,652        | 1,344        |
| G2, regelverk kjent | 0,815        | 0,584        | 0,939        |
| G2, regelverk fryst | 1,127        | 0,626        | 1,411        |

**Kurvene skiller lag et bestemt sted.** På én til tre måneder ligger kjent og fryst nær hverandre, og begge godt under den naive. Fra rundt seks måneder krysser den røde kurven over den grå.

**Hvorfor fordelingen gir bildet.** De vedtaksavhengige regressorene er trappefunksjoner med få trinn. Innenfor tre måneder fra en gitt opprinnelse er sannsynligheten liten for at et trinn faller i intervallet, så den fryste og den kjente regressoren er stort sett samme verdi. På tolv måneders sikt inneholder vinduet nesten alltid minst ett trinn — og det faller i akkurat de månedene som betyr mest.

**Hva dette avgjør.** Fortrinnet på kort sikt er ekte og overlever at framtidige vedtak er ukjente: 0,652 mot naivs 0,739. Fortrinnet på lang sikt gjør det ikke. Der går modellen fra 25 % bedre enn naiv til 20 % dårligere. **Tolvmånedersprognosen er ikke en prognose. Den er en beregning betinget av at regelverkskalenderen er kjent et år fram.**

Det gjør den ikke ubrukelig — det er nettopp slik en etat vil bruke den, med vedtatt regelverk lagt inn. Men den skal presenteres som et regnskap under gitte regler, ikke som en framskrivning. Forskjellen er ikke retorisk: den avgjør hvem som eier usikkerheten når reglene endrer seg.

## 4.5 Kapasitet

En naturlig neste tanke er at mer fleksible modeller ville gjort det bedre. Notebook 04 prøver den tanken direkte, med en stige av nevrale nett fra 8 til 128 skjulte enheter.

**Belegg:** Treningstilpasningen stiger fra  $R^2 = 0,650$  til 0,989 mens prognosefeilen stiger fra MASE 0,767 til 0,964. De to kolonnene løper motsatt vei gjennom hele stigen. Modellen med 128 enheter har flere parametre enn treningssettet har rader.

Dette er overtilpasning målt framfor antatt, og det er verdt å understreke hvorfor det er mer enn en lærebokillustrasjon: det betyr at kapasitet ikke er en knapp faktor her. Datagrunnlaget er 114 måneder. Å legge til modellkompleksitet er å bruke frihetsgrader på noe som ikke finnes.

En beslektet observasjon fra samme notebook: panelet av seksten serier hjelper den lineære modellen mye (MASE 1,454 med bare Oslo, 0,767 med alle seksten) og nettet lite ( $1,166 \rightarrow 0,964$ ). Forklaringen er ikke først og fremst variansreduksjon. Nitten koeffisienter lar seg ikke feste med 84 observasjoner, og lar seg feste med 672. **Panelet gjør en enkel modell identifiserbar, mer enn det gjør en fleksibel modell stabil.** Dette er avlest av en kurve som ble tegnet etter at prognosene forelå, og er derfor ført som *beskrivelse*, ikke som test.


## 5 Usikkerhet: intervaller som holder det de lover

Et punkttestimat uten usikkerhet er ubrukelig for planlegging. Spørsmålet er om usikkerheten kan angis *riktig*.

### 5.1 Lekkasje i arbeidsverk 1

Arbeidsverk 1 etterkalibrerer intervallene konformalt: for horisont  $h$  og opprinnelse  $\tau$  bygges intervallet av den empiriske kvantilen til  $|e_h|$  fra tidligere opprinnelser. «Tidligere opprinnelse» ble implementert som *tidligere i rekkefølgen*.

Men en prognosefeil er ikke kjent ved opprinnelsen. Feilen fra opprinnelse  $t_j$  på horisont  $h$  realiseres i  $t_j + h$ . Ved opprinnelse  $t_i$  er den derfor bare tilgjengelig hvis  $t_j + h \leq t_i$ . Arbeidsverk 1 krever bare  $t_j < t_i$ . For  $h = 1$  er de to kravene like. For  $h = 12$  er de det ikke i det hele tatt: kalibreringen bruker da feil som først blir kjent opptil elleve måneder etter at intervallet skulle vært stilt.



Figur 5: Hva de lovede 80 prosentene faktisk blir. Alle fire søylene er regnet på de samme 270 prognosepunktene, slik at forskjellene ikke er utvalgsforskjeller.

**Hva vi ser på.** En dekomponering av avstanden mellom lovet og oppnådd dekning. Arbeidsverk 1s kalibrering treffer 78,5 % — nesten i mål. Fjerner man lekkasjen, faller den til 67,4 %. Legger man så til den endelig-utvalgs-gyldige kvantilen  $\lceil (n+1)(1-\alpha) \rceil / n$ , som split-konformal krever og som ingen av notebookene før 06 brukte, stiger den til 74,4 %. Fem og et halvt prosentpoeng står igjen.

**Hvorfor fordelingen gir bildet.** Med  $n$  kalibreringspunkter er den empiriske 80-prosentkvantilen ikke forventningsrett for populasjonskvantilen. Den ligger systematisk for lavt, fordi  $|e|$

er høyreskjev og fordi en ordensstatistikk i et lite utvalg er skjev. Feilen går som  $1/n$ , og med  $n$  mellom ti og tjue — som er hva de lange horisontene faktisk har — er den synlig framfor neglisjerbar.

**Hva som står igjen — og hvorfor det ikke lot seg avgjøre.** Den nærliggende forklaringen på de siste 5,5 prosentpoengene er at bruddmånedene bryter utbyttbarheten, som er hele forutsetningen for konformal kalibrering. Den hypotesen lot seg ikke prøve, og grunnen er i seg selv et funn:

**Belegg:** 92 % av evalueringspunktene ligger innenfor tre måneder av en datert regelendring. Intervensjonstabellen har tjue oppføringer, og i 2021–2025 kommer de så tett at det knapt finnes rolige måneder å sammenlikne med. Stratifiseringen får 22 punkter mot 248, og forskjellen den viser — 77 mot 73 % — peker riktig vei, men hviler på for lite til å avgjøre noe.

Arbeidsverk 1 regner ut den samme bruddnær-variabelen og bruker den aldri. Nå er det målt hvorfor. For en etat er dette mer enn en statistisk detalj: i denne perioden *var* regelverket i praksis alltid i endring, og en modell som forutsetter en rolig grunntilstand har ingen grunntilstand å hvile på.

## 5.2 Et tall som var større enn det så ut som

Notebook 05 kalibrerer på prognosefeilene fra alle seksten seriene, og fikk fire til fem ganger så mange kalibreringspunkter. Løftet i dekning var mindre enn det burde tilsi.

**Belegg:** Kalibreringspunktene på tvers av serier er sterkt avhengige: gjennomsnittlig korrelasjon mellom to seriers absolutte logfeil er 0,90 på  $h = 1$  og 0,62 på  $h = 12$ . Effektiv dimensjon er 1,2 til 2,0 av 16. De 304 punktene ved  $h = 12$  er informasjonsmessig verdt om lag 38.

Det som ble målt i notebook 05, var at de seksten seriene har sammenliknbare *marginale* feilfordelinger. Det er riktig, og det er ikke det samme som utbyttbarhet. Et månedsavvik som treffer Oslo, treffer alle bydelene samtidig, fordi det er regelverket og ikke bydelen som flytter tallet.

## 6 Hierarkiet: Oslo og de femten delene

Prognosene for de seksten seriene summerte ikke opp. Bydelene ble prognostisert hver for seg, og summen deres var ikke Oslo-prognosen. Notebook 06 avstemmer dem med fire metoder: bottom-up, top-down, og MinT med to kovariansvalg.

| Metode                   | MASE Oslo    | MASE bydel, snitt | Koherensavvik |
|--------------------------|--------------|-------------------|---------------|
| Basis (ingen avstemming) | <b>0,767</b> | 0,836             | 190 husst.    |
| Bottom-up                | 0,825        | 0,836             | 0             |
| Top-down                 | 0,767        | 0,819             | 0             |
| MinT, $W = I$            | 0,770        | <b>0,797</b>      | 0             |
| MinT, krymping           | 0,796        | 0,818             | 0             |

**Hvordan tabellen skal leses.** Kolonne to og tre løper motsatt vei. Den metoden som er best for bydelene, MinT med  $W = I$ , er nest dårligst for Oslo. Bottom-up — å summere femten bydelsprognoser til en Oslo-prognose — er tydelig verst for totalen.

**Hvorfor fordelingen gir bildet.** Bydelene har mellom 363 og 2 212 mottakere i snitt; Oslo har 17 000. Å summere femten støyende prognoser gir mer varians enn å prognostisere totalen direkte. Motsatt vei har den velestimerte totalen mye å gi de støyende bydelene. Avstemming er derfor **ikke en måte å forbedre totalen på; det er en måte å forbedre delene på**, og prisen er en liten forverring på toppen.

**En praktisk grense ved MinT.** MinT med estimert kovarians er dårligere enn MinT med  $W = I$ , på begge nivåer. Krympingsintensiteten lander på 0,15 i median, altså brukes i hovedsak den rå kovariansmatrisen — og den er estimert på så få punkter at den bærer mer støy enn informasjon. Optimaliteten MinT lover, forutsetter en  $W$  man her ikke kan estimere.

## 7 Kvalitetskontrollen: hva som ikke overlevde

De seks første notebookene forhåndsregistrerte til sammen nitten påstander med avgjørelseskriterium skrevet ned før tallene fantes. Det gjør dem kontrollerbare på en måte de fleste analyser ikke er: man kan i ettertid spørre om avgjørelsen ble tatt med riktig instrument. Notebook 07 stiller det spørsmålet for de seks konklusjonene som bærer mest vekt. Fem av dem tålte ikke spørsmålet.

### 7.1 To påstander som er trukket

«**Ingen trebasert modell skiller seg fra den naive.**» Sammenlikningen er nøstet. Alle modellene i stigen har formen  $\hat{y}_{t+h} = \log y_t + f(x_t)$ , og den naive prognosen er nøyaktig det samme uttrykket med  $f \equiv 0$ . Under nullhypotesen om at  $f$  ikke bidrar, estimerer den store modellen likevel  $f$  og betaler for det i varians. Diebold–Mariano regner den kostnaden som bevis for at den lille modellen er bedre. Clark–West fjerner den.

**Belegg:** Med Diebold–Mariano passerer **0 av 36** celler den kritiske verdien 1,64. Med Clark–West passerer **13 av 36**, med opptil 2,80. Korreksjonsleddet  $(e_1 - e_2)^2$  er positivt per konstruksjon, så forskjellen er systematisk og ikke støy. Notebook 02 skrev regelen ned og implementerte grenen som `noestet=True`; notebook 03 kalte funksjonen uten den.

«**Den sterkeste effekten i hele arbeidsverk 2.**» Bydelsgevinsten ble testet ved å stable femten bydelers tapsdifferanser i én vektor og behandle den som 465 uavhengige observasjoner.

**Belegg:** Gjennomsnittlig korrelasjon mellom to bydelers tapsdifferanse er **0,81**, og effektiv dimensjon er 1,43 av 15 — samme egenskap ved bydelene som notebook 01 målte og notebook 06 brukte til å forutsi et annet resultat. Med klynging på opprinnelse (31 observasjoner) faller statistikken fra 5,38 til 1,56 på  $h = 1$  og fra 2,99 til 0,91 på  $h = 12$ . MASE-forbedringen  $0,836 \rightarrow 0,797$  er upåvirket.

Standardfeilen til et gjennomsnitt av  $K$  korrelerte størrelser går ikke som  $1/\sqrt{K}$ , men mot en grense satt av korrelasjonen: med  $\rho \approx 0,8$  og  $K = 15$  er den effektive prøvestørrelsen i underkant av to. Å stable femten bydeler er derfor nesten ikke å legge til data.

### 7.2 En rapporteringsvane som skjulte et mønster

Notebook 03, 04 og 06 rapporterer alle  $h \in \{1, 3, 6, 12\}$ . Konvensjonen er arvet fra arbeidsverk 1 og er i seg selv rimelig — fire tall er lesbare, tolv er det ikke. Men den er et utvalg, og her viste den seg å velge feil.

På de fire horisontene ser Clark–West-statistikken ut som en kurve som faller under den kritiske verdien etter tre måneder. Over alle tolv gjør den ikke det: den passerer i 13 av 36 celler, spredt over hele horisontspennet. Det som faktisk skjer, er at testen mister styrke med horisonten fordi langvariansen bruker  $L = h - 1$  lag på et fast antall opprinnelser. Det er en egenskap ved testoppsettet, ikke ved serien.

Konsekvensen er ikke at fire horisonter er galt å vise. Den er at *konklusjoner* skal trekkes fra alle tolv, og at en tabell som viser fire, bør si hva de tolv gjorde.

### 7.3 En kontroll som ikke kunne feile

Notebook 03 hadde to lekkasjekontroller. Den ene er ekte. Den andre var skrevet slik at konklusjonen fulgte av forutsetningen: variabelen som skulle testes ble beregnet og aldri

brukt, og påstanden ble utledet på nytt fra en betingelse som allerede inneholdt den.

Notebook 07 erstatter den med en mutasjonstest: funksjonen ødelegges med vilje, og kontrollen må stoppe. Den gamle kontrollen består selv når treningssettet slippes tolv måneder inn i framtiden. Den nye stopper.

Konsekvensen for resultatene er null — funksjonen var faktisk riktig skrevet. Konsekvensen for hva som kan *sies*, er ikke null. En kontroll som ikke er vist å kunne stryke, hører ikke hjemme i et manifest.

## 7.4 Seks dokumenterte metodefeil

| Feil                                     | Hvordan den ble funnet                          | Virkning                               |
|------------------------------------------|-------------------------------------------------|----------------------------------------|
| Kalenderforveksling                      | to eksakte identiteter                          | april 2024: $-0,2 \rightarrow -25,2\%$ |
| Konformal lekkasje                       | $t_j + h \leq t_i$ framfor $t_j < t_i$          | 11 pp dekning                          |
| Nettet ble aldri trent                   | tol slo inn etter 24 av 1500 iterasjoner        | modellstigen var tom                   |
| Radrekkefølge under subsample            | 0,8155 mot 0,8229 fra stablingsrekkefølge alene | reproduserbarhet                       |
| Manglende endelig-utvalgs-korreksjon     | $[(n+1)(1-\alpha)]/n$                           | 7 pp dekning                           |
| Tverrsnittsavhengighet som frihetsgrader | klynging på opprinnelse                         | $5,38 \rightarrow 1,56$                |

De fem første ble funnet mens arbeidet pågikk. Den sjette ble funnet ved å lese egne notebooks som om noen andre hadde skrevet dem. Det er ikke tilfeldig at fem av de seks er *stille* feil: koden kjørte, tallet kom ut, og ingenting varslet. Det er den typen feil et analysemiljø må bygge kontroller mot, fordi den ikke oppdages av at noe går galt.

## 8 Anbefalinger

### 8.1 Til forskningsspørsmålet

Spørsmålet arbeidet begynte med, var: *hvor mange husstander vil motta statlig bostøtte i Oslo de neste tolv månedene?* Tre funn taler for at det spørsmålet bør deles i to — og det er ikke delingen jeg først trodde. Utkastet til denne rapporten skilte ved tre måneder fordi teststatistikken gjorde det. Målingen i notebook 07 viser at skillet går et annet sted, og av en annen grunn.

1. **Skill mellom en prognose og et regnskap — ikke mellom kort og lang horisont.** Modellen slår den naive framskrivningen på alle tolv horisontene, med en relativ margin som er nesten konstant. Det som ikke er konstant, er hva marginen er kjøpt med. På tre måneders sikt kommer den fra serien og fra regelverk som allerede er kjent. På tolv måneders sikt kommer den fra regelverk som ennå ikke er vedtatt på prognosetidspunktet.

**Belegg:** Med regressorene fryst ved opprinnelsen: MASE på  $h = 1-3$  går fra 0,584 til 0,652, fortsatt under naivs 0,739. På  $h = 6-12$  går den fra 0,848 til 1,344, mot naivs 1,124. Fortrinnet inverteres.

2. **Publiser tolvmånederstallet som betinget, med betingelsen skrevet ut.** Det er nyttig — det er slik en etat vil bruke det. Men det skal stå hvilke vedtak det forutsetter, og hva som skjer med tallet hvis de ikke kommer. Presenteres det som en framskrivning, blir en politisk beslutning lest som en spådom, og usikkerheten havner hos feil part.

**Belegg:** Ablasjonen: uten regelverksregressorene i det hele tatt faller alle fire modellklassene under naiv ( $0,77 \rightarrow 1,50$  for den beste).

3. **Flytt spørsmålet ned til bydel.** Avstemming forbedrer bydelsprognosene og forverrer totalen litt. Bydelene er også der beslutningene tas. Om det bare skal produseres ett tallsett, er bydelsnivået det som gir mest igjen for modelleringen.

**Belegg:** MASE over bydelene  $0,836 \rightarrow 0,797$  med MinT; Oslo-totalen  $0,767 \rightarrow 0,770$ .

Et fjerde punkt hører hjemme her, som en advarsel framfor en anbefaling. Serien har en egenskap som gjør den vanskelig på en spesiell måte: den er nesten flat mellom regelendringer og hopper kraftig ved dem. Det betyr at gjennomsnittlig treffsikkerhet er et misvisende mål — en modell kan ha lav MASE og likevel bomme fullstendig på nettopp de månedene noen bryr seg om. Intervallskår og bruddnær dekning bør stå ved siden av MASE i enhver rapportering.

## 8.2 Til prosjektet

1. **Bygg en versjonert regelverkstabell med kjent-fra-dato.** Dette er den mest verdifulle neste komponenten, og den er ikke en modell. Tabellen trenger tre datoer per endring: vedtaksdato, kunngjøringsdato, virkningsdato. Med den kan enhver prognose kjøres to ganger — én gang med det som var kjent, én gang med fasit — og forskjellen er da et *målt* usikkerhetsbidrag framfor en advarsel i en fotnote.

**Belegg:** Uten en slik tabell måtte notebook 07 tilnærme «det som var kjent» ved å bære siste verdi framover. Tilnærmingen er konservativ og gir  $0,848 \rightarrow 1,344$  på  $h = 6-12$ ; den sanne verdien ligger mellom de to, og en kjent-fra-dato ville avgjort hvor.

2. **Legg til driftsovervåkning — og varsle på intervallskår, ikke på MASE.** Dette er den ene komponenten stillingsutlysningen navngir som arbeidet ikke har. MASE-nevneren regnes i treningsvinduet og vokser når serien blir mer volatil, så MASE *faller* når verden blir vanskeligere. Intervallskåren straffer bom direkte og har ikke den egenskapen.

**Belegg:** Notebook 02, avsnitt 4: nevneren er sesongnaiv feil i treningsvinduet ved hver opprinnelse, så MASE er ikke sammenliknbar på tvers av perioder.

3. **Lukk de to åpne punktene som er billige.** Ingen hyperparametersøk og ett frø. Begge er ført opp som åpne i notebook 03 og 04. Et søk krever nestet kryssvalidering innenfor hvert treningsvindu; spredning over frø krever bare å kjøre det samme flere ganger. Ingen av resultatene her sier noe om hva modellene kunne oppnådd med justering, og det bør de kunne si.
4. **Be om individdata.** Gruppemekanismen i april 2024 ble sannsynliggjort med en eksakt permutasjonstest over fem grupper,  $p = 2/120$ . Det er den sterkeste testen som er mulig med fem grupper, og den er svak. Med husstands nivå er den samme mekanismen direkte målbar, og egenandelsstrukturen kan simuleres framfor estimeres.
5. **Skriv ferdig det som er lovet.** BSTS er nevnt i repositoriets README og ikke levert. Notebook 01 har to avsnitt som fortsatt er punktlistor. Et arbeid som ellers skiller nøye mellom kontrollert og antatt, bør ikke ha løfter stående som ikke er innfridd.

## 8.3 Til Velferdsetaten

1. **Publiser intervaller, ikke punkter — og oppgi den målte dekningen.** Et 80 %-intervall som treffer 74 % er brukbart hvis det står at det treffer 74 %. Det er ubrukelig hvis



det står 80. Arbeidet her viser at avstanden mellom lovet og oppnådd dekning er stor nok til å ha praktisk betydning, og at den lar seg måle.

2. **Bruk bydelsnivået, og avstem det.** Bydelene tar beslutningene, og det er der modellering betaler seg. Avstemming koster nesten ingenting på totalen og gir en gjennomsnittlig forbedring på bydelsnivå.
3. **Institusjonaliser regelverkskalenderen.** Dette er den anbefalingen som krever minst teknisk kapasitet og gir mest. En datert, versjonert oversikt over regelendringer i bostøtten — med kunngjøringsdato, ikke bare virkningsdato — er en ren forvaltningsoppgave, og den er en forutsetning for at enhver modell skal virke. Uten den er den beste modellen i dette arbeidet dårligere enn å gjette.
4. **Vær varsom med bydelspooling.** Femten bydeler er ikke femten uavhengige observasjoner. Effektiv dimensjon er 1,2 av 15 på nivåene og 1,4 av 15 på prognosefeilene. Enhver analyse som slår sammen bydeler og rapporterer signifikans — ikke bare prognosearbeid — risikerer å overdrive styrken på sine funn med en faktor rundt tre. Denne feilen ble gjort i dette arbeidet og fanget i kvalitetskontrollen. Den er lett å gjøre.
5. **Ikke regn med en rolig grunntilstand.** 92 % av evalueringspunktene ligger innenfor tre måneder av en datert regelendring. Det betyr at «normal drift» ikke er en tilstand denne serien har vært i på fem år, og at enhver metode som kalibrerer på rolige perioder mangler noe å kalibrere på. Praktisk følge: bygg regelendringer inn som en forventet del av modellen framfor som avvik fra den, og ikke bruk historisk gjennomsnittlig treffsikkerhet som løfte om framtidig.
6. **Sett krav til analyseleveranser, ikke bare til leveransen.** Fire krav ville fanget alle seks feilene dokumentert her, og de koster lite å stille: forhåndsregistrering av påstander med avgjørelseskriterium; en protokoll som er reprodusert uavhengig; lekkasjekontroller som er vist å kunne stryke; og en endringslogg som bærer grunnen til hver endring. Dette gjelder like mye for innkjøpt analyse som for egenprodusert.
7. **Skill mellom prognose og regnskap i det som publiseres.** Antall bostøttemottakere om tolv måneder er i hovedsak et spørsmål om hvilke regler som gjelder da. Presenteres det som en prognose, blir en politisk beslutning lest som en framskrivning. Presenteres det som et regnskap under gitte regler, blir det et beslutningsgrunnlag.

## 9 Hva som står åpent

Ærlighet om det som ikke er gjort, hører til i samme rapport som det som er.

- **Ingen hyperparametersøk, ett frø.** Resultatene sier ingenting om hva modellene kunne oppnådd med justering, og spredningen mellom frø er ukjent.
- **Seks trinn i modellstigen er avskrift.** De er merket slik i hver tabell. Diebold–Mariano-implementasjonen er gjengitt fra arbeidsverk 1 ledd for ledd, men ikke kontrollert mot et publisert tall, fordi arbeidsverk 1 bare rapporterer par som involverer en modell som ikke er reprodusert her.
- **Ingen driftskomponent.** Ingen drift-deteksjon, ingen retreningspolicy, ingen overvåkning. Se anbefaling 2 til prosjektet.
- **«Det som var kjent» er tilnærmet, ikke dokumentert.** Frysingen i notebook 07 bærer siste verdi framover. Det er konservativt — i virkeligheten var noen vedtak kjent før virkningsdato. Uten en kunngjøringsdato per endring er den sanne betingede treffsikkerheten et intervall, ikke et tall.

- **Kvalitetskontrollen er ikke uttømmende.** Notebook 07 prøver de seks konklusjonene som bærer mest vekt. Fravær av flere funn der er ikke belegg for at det ikke finnes flere.
  - **Uttrekket selv er ikke kontrollert.** Om Husbankens tall er riktige, ligger utenfor det som kan avgjøres herfra.
  - **Bruddmånedsforklaringen er ikke testet.** Stratifiseringen peker den veien. Den er beskrivelse, ikke test.
- 

Alt tallmateriale i denne rapporten er regnet på nytt fra kildedataene i notebook 07, uten å lese resultater fra notebook 01–06. Notebookene ligger i [github.com/Torcode/bostotte-oslo](https://github.com/Torcode/bostotte-oslo) under notebooks/, og hver av dem sammenlikner sitt eget kildeavtrykk med det som ligger på main før den rapporterer noe. Endringsloggen i `logg/` bærer grunnen til hver endring.